

Universitat Autònoma de Barcelona
Facultat de Ciències

MODELITZACIÓ I INFERENCIA
PRÀCTICA 2

Autor:

Gerard Lahuerta Martín
NIU: 1601350

2 de Desembre del 2021

Índex

| | | |
|---|------------------------------|---|
| 1 | Presentació del problema | 3 |
| 2 | Resolució del primer apartat | 4 |
| 3 | Resolució del segon apartat | 5 |
| 4 | Resolució del tercer apartat | 6 |
| 5 | Resolució del quart apartat | 7 |

1 Presentació del problema

Suposa una mostra aleatòria X_1, \dots, X_n distribuïda segons una $Weibull(\alpha, k)$ amb la següent funció de densitat:

$$f_X(x|\alpha, k) = \frac{k}{\alpha} x^{k-1} e^{-\frac{x^k}{\alpha}}, \quad x > 0, \alpha, k > 0$$

Considera $k = 2$.

- (a) Troba l'estimador de màxima versemblança per a α , i comprova que el que has trobat és un maximitzador de la funció de versemblança.
- (b) Demostra que l'estimador de màxima versemblança de α , $\hat{\alpha}$, és un estimador no esbiaixat per a α .

Pista: Per a resoldre aquest exercici, necessites trobar primer la distribució de X_i^2 sabent que $X_i \sim Weibull(\alpha, 2)$. Pots fer la demostració a partir de la distribució de probabilitat acumulada (CDF) sabent que:

$$\mathbb{P}(X_i^2 \leq c) = \mathbb{P}(X_i \leq \sqrt{c}) = \int_0^{\sqrt{c}} f_{X_i}(x_i|\alpha) dx_i$$

- (c) Calcula la informació de Fisher esperada per a α
- (d) És $\hat{\alpha}$ l'estimador per a α més eficient entre tots els estimadors no esbiaixats? Justifica la teva resposta.

2 Resolució del primer apartat

Trobem l'estimador de màxima versemblança per a α (que anomenarem $\hat{\alpha}$) a partir del seu *MLE* (*Most Likelihood Estimator*): Calculem la funció de versemblança, la log-versemblança i la funció "score":

- Funció de versemblança: $L(\alpha|x)$

$$L(\alpha|x) = \prod_{i=1}^n f_{X_i}(x_i|\alpha, 2) = \prod_{i=1}^n \left(\frac{2}{\alpha} x_i e^{-\frac{x_i^2}{\alpha}} \right) = \left(\frac{2}{\alpha} \right)^n e^{-\frac{\sum_{i=1}^n x_i^2}{\alpha}} \prod_{i=1}^n x_i$$

- Funció de log-versemblança: $l(\alpha|x) = \log(L(\alpha|x))$

$$\begin{aligned} l(\alpha|x) &= \log \left[\left(\frac{2}{\alpha} \right)^n e^{-\frac{\sum_{i=1}^n x_i^2}{\alpha}} \prod_{i=1}^n x_i \right] = n \log \left(\frac{2}{\alpha} \right) - \frac{\sum_{i=1}^n x_i^2}{\alpha} + \log \left(\prod_{i=1}^n x_i \right) = \\ &= n(\log(2) - \log(\alpha)) - \frac{1}{\alpha} \sum_{i=1}^n (x_i^2) + \sum_{i=1}^n (\log(x_i)) \end{aligned}$$

- Funció score: $s(\alpha|x) = \frac{\partial}{\partial \alpha} l(\alpha|x)$

$$\begin{aligned} s(\alpha|x) &= \frac{\partial}{\partial \alpha} \left(n(\log(2) - \log(\alpha)) - \frac{1}{\alpha} \sum_{i=1}^n (x_i^2) + \sum_{i=1}^n (\log(x_i)) \right) = \\ &= \frac{1}{\alpha^2} \sum_{i=1}^n (x_i^2) - \frac{n}{\alpha} \end{aligned}$$

- Igualem la funció score a 0 per a trobar el màxim.

$$\begin{aligned} s(\alpha|x) = 0 &\iff \frac{1}{\alpha^2} \sum_{i=1}^n (x_i^2) - \frac{n}{\alpha} = 0 \implies \frac{1}{\alpha^2} \sum_{i=1}^n (x_i^2) = \frac{n}{\alpha} \implies \frac{1}{n} \sum_{i=1}^n (x_i^2) = \alpha \implies \\ &\implies \hat{\alpha} = \frac{1}{n} \sum_{i=1}^n (x_i^2) \end{aligned}$$

- Comprovem ara que el valor de l'estimador $\hat{\alpha}$ trobat es el màxim a partir del signe de la derivada de la funció score: $s'(\alpha|x)$.

$$\begin{aligned} s'(\alpha|x) &= \frac{-2}{\alpha^3} \sum_{i=1}^n (x_i^2) + \frac{n}{\alpha^2} \underset{(\alpha = \hat{\alpha})}{=} -2n^3 \left(\sum_{i=1}^n (x_i^2) \right)^{-2} + n^3 \left(\sum_{i=1}^n (x_i^2) \right)^{-2} = \\ &= -n^3 \left(\sum_{i=1}^n (x_i^2) \right)^{-2} < 0 \text{ ja que } n \in \mathbb{N}(n > 0) \text{ i } \left(\sum_{i=1}^n (x_i^2) \right)^{-2} \in \mathbb{R}^+ \implies \\ &\implies \boxed{\hat{\alpha} = \frac{1}{n} \sum_{i=1}^n (x_i^2) \text{ és realment l'estimador de màxima versemblança per } \alpha} \end{aligned} \tag{1}$$

3 Resolució del segon apartat

Comprovem si l'estimador $\hat{\alpha}$ trobat a l'apartat anterior és no esbiaixat, sabent que no ho serà si i nomès si $Bias(\hat{\alpha}) = 0$. Calculem el $Bias(\hat{\alpha}) = E(\hat{\alpha}) - \alpha$, calculant previamente l'esperança de l'estimador: $E(\hat{\alpha})$

- Càlcul de l'esperança de l'estimador $\hat{\alpha} : E(\hat{\alpha})$

$$E(\hat{\alpha}) = E\left(\frac{1}{n} \sum_{i=1}^n (X_i^2)\right) \underset{(I)}{=} E(X_i^2)$$

(I): X_1, \dots, X_n independents i idènticament distribuïdes

- Calculem ara $E(X_i^2)$ trobat la distribució de X_i^2 :

$$\begin{aligned} \mathbb{P}(X_i^2 \leq u) &= \mathbb{P}(X_i \leq \sqrt{u}) = \int_0^{\sqrt{u}} \left(\frac{2}{\alpha} x_i e^{-\frac{x_i^2}{\alpha}} \right) dx = 1 - e^{-\frac{u}{\alpha}} \implies \\ \implies X_i^2 &= \left(1 - e^{-\frac{x_i}{\alpha}} \right)' = \frac{1}{\alpha} e^{-\frac{x_i}{\alpha}} \implies \\ \implies E(X_i^2) &= \int_0^\infty \frac{1}{\alpha} x e^{-\frac{x}{\alpha}} dx = \left[-(\alpha + x) e^{-\frac{x}{\alpha}} \right]_0^\infty = 0 - (-\alpha) = \alpha \end{aligned} \tag{2}$$

- Calculem ara el $Bias(\hat{\alpha})$:

$$Bias(\hat{\alpha}) = E(\hat{\alpha}) - \alpha = \alpha - \alpha = 0 \implies \boxed{\text{L'estimador } \hat{\alpha} \text{ és no esbiaixat}}$$

4 Resolució del tercer apartat

Calculem l'informació de Fisher esperada per a α : $J(\alpha)$, calculant previament l'informació observada de Fisher, $I(\alpha)$.

- L'informació observada de Fisher: $I(\alpha) = -s'(\alpha)$ calculada anteriorment a l'apartat 2.1

$$I(\alpha) = -\frac{n}{\alpha^2} + \frac{2}{\alpha^3} \sum_{i=1}^n (x_i^2)$$

- Informació de Fisher esperada: $J(\alpha) = E(I(\alpha))$

$$J(\alpha) = E\left(\frac{-n}{\alpha^2} + \frac{2}{\alpha^3} \sum_{i=1}^n (x_i^2)\right) = \frac{-n}{\alpha^2} + \frac{2n}{\alpha^3} E(x_i^2) \underset{\substack{\uparrow \\ \text{(II)}}}{=} \frac{-n}{\alpha^2} + \frac{2n}{\alpha^2} = \frac{n}{\alpha^2} \implies$$

$\implies \text{L'informació de Fisher esperada per a } \alpha \text{ és: } J(\alpha) = \frac{n}{\alpha^2}$

(II): $E(X_i^2) = \alpha$ la sabem per l'apartat 3.2

5 Resolució del quart apartat

Sabem que el millor estimador no esbiaixat serà aquell que tingui una menor variança. Per descobrir si $\hat{\alpha}$ és el millor estimador calculem la seva variança: $V(\hat{\alpha})$.

- Calculem $V(\hat{\alpha})$:

$$V(\hat{\alpha}) = V\left(\frac{1}{n} \sum_{i=1}^n (X_i)^2\right) = \frac{1}{n^2} V\left(\sum_{i=1}^n (X_i)^2\right) = \frac{1}{n} V(X_i^2)$$

- Calculem $V(X_i^2)$:

$$\left. \begin{aligned} V(X_i^2) &= E((X_i^2)^2) - E(X_i^2)^2 = E((X_i^2)^2) - \alpha^2 \\ E(\hat{\alpha}^2) &= \int_0^\infty x^2 \frac{1}{\alpha} e^{-\frac{x}{\alpha}} dx = \left[-(x^2 + 2x\alpha + 2\alpha^2) e^{-\frac{x}{\alpha}} \right]_0^\infty = 2\alpha^2 \end{aligned} \right\} \Rightarrow$$

$$\Rightarrow V(X_i^2) = \alpha^2 \Rightarrow V(\hat{\alpha}) = \frac{\alpha^2}{n}$$

Sabem, també, que la Cota de Cramer-Rao ($CR = J^{-1}(\alpha)$) ens diu si un estimador és o no eficient i, a més, si es el més eficient. Serà l'estimador més eficient si la seva variança és igual a la Cota de Cramer Rao.

- Calculem doncs la Cota de Cramer Rao:

$$CR = J^{-1}(\alpha) = \frac{1}{\frac{n}{\alpha^2}} = \frac{\alpha^2}{n}$$

Observem que $CR = V(\alpha) \Rightarrow$

\Rightarrow L'estimador $\hat{\alpha}$ és el millor d'entre tots els estimadors no esbiaixats